

고객을 세그멘테이션하자 [프로젝트] - 허재민

11-2. 데이터 불러오기

데이터 살펴보기

- 테이블에 있는 10개의 행만 출력하기

```
SELECT *
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
LIMIT 10;
```

[결과 이미지를 넣어주세요]

- 전체 데이터는 몇 행으로 구성되어 있는지 확인하기

```
SELECT *
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
```

[결과 이미지를 넣어주세요]

데이터 수 세기

- COUNT 함수를 사용해서, 각 컬럼별 데이터 포인트의 수를 세어 보기

```
SELECT COUNT(InvoiceNo) AS COUNT_InvoiceNo,
COUNT(StockCode) AS COUNT_StockCode,
COUNT(Description) AS COUNT_Description,
COUNT(Quantity) AS COUNT_Quantity,
COUNT(InvoiceDate) AS COUNT_InvoiceDate,
COUNT(UnitPrice) AS COUNT_UnitPrice,
COUNT(CustomerID) AS COUNT_CustomerID,
COUNT(Country) AS COUNT_Country
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
LIMIT 1
```

[결과 이미지를 넣어주세요]

쿼리 결과							
작업 정보		결과	시각화	JSON	실행 세부정보	실행 그래프	
행	COUNT_InvoiceNo	COUNT_StockCode	COUNT_Description	COUNT_InvoiceD	COUNT_UnitPrice	COUNT_CustomerID	COUNT_Country
1	541909	541909	540455	541909	541909	406829	541909

11-4. 데이터 전처리 방법(1): 결측치 제거

컬럼 별 누락된 값의 비율 계산

- 각 컬럼 별 누락된 값의 비율을 계산
 - 각 컬럼에 대해서 누락 값을 계산한 후, 계산된 누락 값을 UNION ALL을 통해 합치기

```

SELECT
    'InvoiceNo' AS column_name,
    ROUND(SUM(CASE WHEN InvoiceNo IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2) AS missing_percentage
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
UNION ALL
SELECT
    'StockCode' AS column_name,
    ROUND(SUM(CASE WHEN StockCode IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2) AS missing_percentage
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
UNION ALL
SELECT
    'Description' AS column_name,
    ROUND(SUM(CASE WHEN Description IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2) AS missing_percentage
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
UNION ALL
SELECT
    'Quantity' AS column_name,
    ROUND(SUM(CASE WHEN Quantity IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2) AS missing_percentage
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
UNION ALL
SELECT
    'InvoiceDate' AS column_name,
    ROUND(SUM(CASE WHEN InvoiceDate IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2) AS missing_percentage
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
UNION ALL
SELECT
    'UnitPrice' AS column_name,
    ROUND(SUM(CASE WHEN UnitPrice IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2) AS missing_percentage
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
UNION ALL
SELECT
    'CustomerID' AS column_name,
    ROUND(SUM(CASE WHEN CustomerID IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2) AS missing_percentage
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
UNION ALL
SELECT
    'Country' AS column_name,
    ROUND(SUM(CASE WHEN Country IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2) AS missing_percentage
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`

```

[결과 이미지를 넣어주세요]

결측치 처리 전략

- `StockCode = '85123A'` 의 `Description` 을 추출하는 쿼리문을 작성하기

```
SELECT DISTINCT Description
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
WHERE StockCode = '85123A';
```

[결과 이미지를 넣어주세요]

쿼리 결과		+ 대용량 보기	결과 저장	다음에서 열기	🔄
작업 정보	결과	시각화	JSON	실행 세부정보	실행 그래프
명	Description				
1	WHITE HANGING HEART FLAG...				
2	?				
3	wrongly marked carton 22804				
4	CREAM HANGING HEART FLAG...				

결측치 처리

- DELETE 구문을 사용하며, WHERE 절을 통해 데이터를 제거할 조건을 제시

```
DELETE FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
WHERE CustomerID IS NULL
OR Description IS NULL;
```

[결과 이미지를 넣어주세요]

쿼리 결과		+ 대용량 보기	결과 저장	다음에서 열기	🔄
작업 정보	결과	실행 세부정보	실행 그래프		
이 문으로 data의 행 135,080개가 삭제되었습니다.					
데이터를 다음					

11-5. 데이터 전처리(2): 중복값 처리

중복값 확인

- 중복된 행의 수를 세어보기
 - 8개의 컬럼에 그룹 함수를 적용한 후, COUNT가 1보다 큰 데이터를 세어보기

```
SELECT InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, Country, COUNT(*) AS `중복된갯수`
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
GROUP BY InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, Country
HAVING COUNT(*) > 1
```

[결과 이미지를 넣어주세요]

쿼리 결과

+ 대용량 보기

결과 저장

다음에서 열기

🔄

작업 정보

결과

시각화

JSON

실행 세부정보

실행 그래프

명	InvoiceNo	StockCode	Description	Quantity	InvoiceDate	UnitPrice	CustomerID	Country	중복된갯수
1	571034	23894	VINTAGE DOLLY DELUXE SEWING...	3	2011-10-13 12:47:00 UTC	5.95	12359	Cyprus	
2	571034	23245	SET OF 3 REGENCY COAT TINS...	4	2011-10-13 12:47:00 UTC	4.95	12359	Cyprus	
3	571034	23239	SET OF 4 KNICK-KNACK TINS FL...	6	2011-10-13 12:47:00 UTC	4.15	12359	Cyprus	
4	538826	22749	FELTCRAFT PRINCESS CHARLO...	1	2010-12-14 12:58:00 UTC	3.75	12370	Cyprus	
5	577228	23048	SET OF 10 LANTERNS FAIRY LL...	1	2011-11-18 12:07:00 UTC	4.15	12391	Cyprus	
6	577228	22270	HAPPY EASTER HANGING DEC...	1	2011-11-18 12:07:00 UTC	3.75	12391	Cyprus	
7	577228	84580	MOUSE TOY WITH PINK T-SHIRT	1	2011-11-18 12:07:00 UTC	3.75	12391	Cyprus	
8	577228	23156	SET OF 5 MINI GROCERY MAG...	1	2011-11-18 12:07:00 UTC	2.08	12391	Cyprus	

결과에서 열기

50

1 - 50 / 181 개 항목

1/2

🔍

🔄

중복값 처리

- 중복값을 제거하는 쿼리문 작성하기

- CREATE OR REPLACE TABLE 구문을 활용하여 모든 컬럼(*)을 DISTINCT 한 데이터로 업데이트

```
CREATE OR REPLACE TABLE `project-23e56097-5f6c-4899-bd8.modulabs_project.data` AS
SELECT DISTINCT *
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
```

[결과 이미지를 넣어주세요]

11-6. 데이터 전처리(3): 오류값 처리

InvoiceNo 살펴보기

- 고유(unique)한 InvoiceNo 의 개수를 출력하기

```
SELECT COUNT(DISTINCT InvoiceNo)
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
```

[결과 이미지를 넣어주세요]

- 고유한 InvoiceNo 를 앞에서부터 100개를 출력하기

```
SELECT InvoiceNo
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
GROUP BY InvoiceNo
ORDER BY InvoiceNo ASC
LIMIT 100;
```

[결과 이미지를 넣어주세요]

- InvoiceNo 가 'C'로 시작하는 행을 필터링 할 수 있는 쿼리문을 작성하기 (100행까지만 출력)

```
SELECT *
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
WHERE InvoiceNo LIKE 'C%'
LIMIT 100;
```

[결과 이미지를 넣어주세요]


```
SELECT DISTINCT StockCode, number_count
FROM (
  SELECT StockCode,
    LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS number_count
  FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
)
WHERE number_count < 5
```

[결과 이미지를 넣어주세요]

번호	StockCode	number_count
1	POST	0
2	M	0
3	C2	1
4	D	0
5	BANK CHARGES	0
6	PADS	0
7	DOT	0
8	CRUK	0

- **StockCode**의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고
 - 숫자가 0~1개인 값들을 가지고 있는 데이터 수는 전체 데이터 수 대비 몇 퍼센트인지 구하기 (소수점 두 번째 자리까지)

```
SELECT
  ROUND(
    COUNTIF(
      LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) < 5
    ) / COUNT(*) * 100,
    2
  ) AS StockCode_A_Ratio
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
```

[결과 이미지를 넣어주세요]

번호	StockCode_A_Ratio
1	0.48

- 제품과 관련되지 않은 거래 기록을 제거하기

```
DELETE FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
WHERE LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) <= 1;
```

[결과 이미지를 넣어주세요]

메시지
이 문으로 data의 행 1,915개가 삭제되었습니다.

Description 살펴보기

- 고유한 Description 별 출현 빈도를 계산하고 상위 30개를 출력하기

```
SELECT Description, COUNT(*) AS description_cnt
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
GROUP BY Description
```

```
ORDER BY description_cnt DESC
LIMIT 30;
```

[결과 이미지를 넣어주세요]

쿼리 결과

작업 정보	결과	시각화	JSON	실행 세부정보	실행 그래프
명	Description	description_cnt			
1	WHITE HANGING HEART TUG...	2058			
2	REGENCY CAKESTAND 3 TIER	1894			
3	JUMBO BAG RED RETROSPOT	1659			
4	PARTY BUNTING	1409			
5	ASSORTED COLOUR BIRD ORN...	1405			
6	LUNCH BAG RED RETROSPOT	1345			
7	SET OF 3 CAKE TINS PANTRY D...	1224			
8	LUNCH BAG BLACK SKULL	1099			

페이지당 결과 수: 50 | 1-30 (전체 30명) | < > >|

- 서비스 관련 정보를 포함하는 행들을 제거하기

```
DELETE
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
WHERE Description = 'High Resolution Image'
OR Description = 'Next Day Carriage';
```

[결과 이미지를 넣어주세요]

쿼리 결과

작업 정보	결과	실행 세부정보	실행 그래프
이 문으로 data의 행 83개가 삭제되었습니다.			

데이터를 이동

- 대소문자를 혼합하고 있는 데이터를 대문자로 표준화 하기

```
CREATE OR REPLACE TABLE `project-23e56097-5f6c-4899-bd8.modulabs_project.data` AS
SELECT
  * EXCEPT (Description),
  UPPER(Description) AS Description
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
```

[결과 이미지를 넣어주세요]

쿼리 결과

작업 정보	결과	실행 세부정보	실행 그래프
이 문으로 이름이 data인 테이블이 교체되었습니다.			

데이터를 이동

UnitPrice 살펴보기

- UnitPrice의 최솟값, 최댓값, 평균을 구하기

```
SELECT MIN(UnitPrice) AS min_price, MAX(UnitPrice) AS max_price, AVG(UnitPrice) AS avg_price
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
```

[결과 이미지를 넣어주세요]

쿼리 결과

작업 정보	결과	시각화	JSON	실행 세부정보	실행 그래프
명	min_price	max_price	avg_price		
1	0.0	649.5	2.904956757406...		

- 단가가 0원인 거래의 개수, 구매 수량(Quantity)의 최솟값, 최댓값, 평균 구하기

```
SELECT COUNT(Quantity) AS cnt_quantity, MIN(Quantity) AS min_quantity, MAX(Quantity) AS max_quantity, AVG(Quantity) AS avg_quantity
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
WHERE Unitprice = 0;
```

[결과 이미지를 넣어주세요]

작업 정보	결과	시각화	JSON	실행 세부정보	실행 그래프
1	cnt_quantity	min_quantity	max_quantity	avg_quantity	
1	33	1	12540	420.5151515151...	

- UnitPrice = 0 를 제거하고 일관된 데이터셋을 유지하기

```
CREATE OR REPLACE TABLE `project-23e56097-5f6c-4899-bd8.modulabs_project.data` AS
SELECT *
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
WHERE Unitprice != 0;
```

[결과 이미지를 넣어주세요]

작업 정보	결과	실행 세부정보	실행 그래프
이 문으로 이름이 data인 데이터베이스가 교체되었습니다.			

11-7. RFM 스코어

Recency

- InvoiceDate 컬럼을 연월일 자료형으로 변경하기

```
SELECT DATE(InvoiceDate) AS InvoiceDay, *
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
```

[결과 이미지를 넣어주세요]

작업 정보	결과	시각화	JSON	실행 세부정보	실행 그래프
1	InvoiceDay	InvoiceNo	StockCode	Quantity	InvoiceDate
1	2011-01-18	541431	23166	74215	2011-01-18 10:01:00 UTC
2	2011-01-18	CS41433	23166	-74215	2011-01-18 10:17:00 UTC
3	2010-12-07	537626	22774	12	2010-12-07 14:57:00 UTC
4	2010-12-07	537626	20780	12	2010-12-07 14:57:00 UTC
5	2010-12-07	537626	21731	12	2010-12-07 14:57:00 UTC
6	2010-12-07	537626	20782	6	2010-12-07 14:57:00 UTC
7	2010-12-07	537626	849970	6	2010-12-07 14:57:00 UTC
8	2010-12-07	537626	22494	12	2010-12-07 14:57:00 UTC

- 가장 최근 구매 일자를 MAX() 함수로 찾아보기

```
SELECT
    MAX(DATE(InvoiceDate)) AS most_recent_date,
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
```

[결과 이미지를 넣어주세요]

쿼리 결과

작업 정보	결과	시각화	JSON	실행 세부정보	실행 그래프
명	most_recent_date				
1	2011-12-09				

- 유저 별로 가장 큰 InvoiceDay를 찾아서 가장 최근 구매일로 저장하기

```
SELECT
  CustomerID,
  MAX(InvoiceDate) AS InvoiceDay
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
GROUP BY CustomerID
```

[결과 이미지를 넣어주세요]

쿼리 결과

작업 정보	결과	시각화	JSON	실행 세부정보	실행 그래프
#	CustomerID	InvoiceDay			
1	12346	2011-01-18			
2	12347	2011-12-07			
3	12348	2011-09-25			
4	12349	2011-11-21			
5	12350	2011-02-02			
6	12352	2011-11-03			
7	12353	2011-05-19			
8	12354	2011-04-21			

- 가장 최근 일자(**most_recent_date**)와 유저별 마지막 구매일(**InvoiceDay**)간의 차이를 계산하기

```
SELECT
  CustomerID,
  EXTRACT(DAY FROM MAX(InvoiceDay) OVER () - InvoiceDay) AS recency
FROM (
  SELECT
    CustomerID,
    MAX(InvoiceDate) AS InvoiceDay
  FROM project_name.modulabs_project.data
  GROUP BY CustomerID
);
```

[결과 이미지를 넣어주세요]

쿼리 결과

작업 정보	결과	시각화	JSON	실행 세부정보	실행 그래프
명	CustomerID	recency			
1	12375	2			
2	12415	24			
3	12778	19			
4	12808	36			
5	12870	366			
6	12908	176			
7	12923	64			
8	13090	8			

- 최종 데이터 셋에 필요한 데이터들을 각각 정제해서 이어붙이고 지금까지의 결과를 **user_r** 이라는 이름의 테이블로 저장하기

```
CREATE OR REPLACE TABLE `project-23e56097-5f6c-4899-bd8.modulabs_project.user_r` AS
SELECT
  CustomerID,
  EXTRACT(DAY FROM MAX(InvoiceDay) OVER () - InvoiceDay) AS recency
FROM (
  SELECT
    CustomerID,
    MAX(InvoiceDate) AS InvoiceDay
  FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
);
```

```
GROUP BY CustomerID
);
```

[결과 이미지를 넣어주세요]

쿼리 결과

작업 정보 결과 실행 세부정보 실행 그래프

이 문으로 이름이 user_rf인 새 테이블이 생성되었습니다.

데이터로 이동

Frequency

- 고객마다 고유한 InvoiceNo의 수를 세어보기

```
SELECT
  CustomerID,
  COUNT(DISTINCT InvoiceNo) AS purchase_cnt
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
GROUP BY CustomerID
```

[결과 이미지를 넣어주세요]

쿼리 결과

작업 정보 결과 시각화 JSON 실행 세부정보 실행 그래프

행	CustomerID	purchase_cnt
1	12346	2
2	12347	7
3	12348	4
4	12349	1
5	12350	1
6	12352	8
7	12353	1
8	12354	1

페이지당 결과 수: 50 1 ~ 50 (전체 4362행) < > >1

- 각 고객 별로 구매한 아이템의 총 수량 더하기

```
SELECT
  CustomerID,
  SUM(Quantity) AS item_cnt
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
GROUP BY CustomerID
```

[결과 이미지를 넣어주세요]

쿼리 결과

작업 정보 결과 시각화 JSON 실행 세부정보 실행 그래프

행	CustomerID	item_cnt
1	18287	1596
2	18283	1355
3	18282	98
4	18281	54
5	18280	45
6	18278	66
7	18277	67
8	18276	184

페이지당 결과 수: 50 1 ~ 50 (전체 4362행) < > >1

- 전체 거래 건수 계산과 구매한 아이템의 총 수량 계산의 결과를 합쳐서 `user_rf` 라는 이름의 테이블에 저장하기

```
CREATE OR REPLACE TABLE `project-23e56097-5f6c-4899-bd8.modulabs_project.user_rf` AS

-- (1) 전체 거래 건수 계산
WITH purchase_cnt AS (
  SELECT
    CustomerID,
    COUNT(InvoiceNo) AS purchase_cnt
  FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
  GROUP BY CustomerID
```

```

),

-- (2) 구매한 아이템 총 수량 계산
item_cnt AS (
    SELECT
        CustomerID,
        SUM(Quantity) AS item_cnt
    FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
    GROUP BY CustomerID
)

-- 기존의 user_r에 (1)과 (2)를 통합
SELECT
    pc.CustomerID,
    pc.purchase_cnt,
    ic.item_cnt,
    ur.reccency
FROM purchase_cnt AS pc
JOIN item_cnt AS ic
    ON pc.CustomerID = ic.CustomerID
JOIN `project-23e56097-5f6c-4899-bd8.modulabs_project.user_r` AS ur
    ON pc.CustomerID = ur.CustomerID;

```

[결과 이미지를 넣어주세요]

Monetary

- 고객별 총 지출액 계산 (소수점 첫째 자리에서 반올림)

```

SELECT
    CustomerID,
    ROUND(SUM(Quantity * UnitPrice),0) AS user_total
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
GROUP BY CustomerID

```

[결과 이미지를 넣어주세요]

row	CustomerID	user_total
1	12346	0.0
2	12347	4310.0
3	12348	1437.0
4	12349	1458.0
5	12350	294.0
6	12352	1265.0
7	12353	89.0
8	12354	1075.0

- 고객별 평균 거래 금액 계산

- 고객별 평균 거래 금액을 구하기 위해 1) `data` 테이블을 `user_rf` 테이블과 조인(LEFT JOIN) 한 후, 2) `purchase_cnt` 로 나누어서 3) `user_rfm` 테이블로 저장하기

```

CREATE OR REPLACE TABLE `project-23e56097-5f6c-4899-bd8.modulabs_project.user_rfm` AS
SELECT
    rf.CustomerID AS CustomerID,
    rf.purchase_cnt,
    rf.item_cnt,

```

```

rf.rececy,
ut.user_total,
ROUND(ut.user_total / rf.purchase_cnt,0) AS user_average
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.user_rf` rf
LEFT JOIN (
  -- 고객 별 총 지출액
  SELECT
    CustomerID,
    ROUND(SUM(Quantity * UnitPrice),0) AS user_total
  FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
  GROUP BY CustomerID
) ut
ON rf.CustomerID = ut.CustomerID;

```

[결과 이미지를 넣어주세요]

번호	CustomerID	purchase_cnt	item_cnt	rececy	user_total	user_average
1	12713	1	605	0	795.0	795.0
2	13298	1	96	1	360.0	360.0
3	13436	1	76	1	197.0	197.0
4	14569	1	79	1	227.0	227.0
5	15520	1	314	1	343.0	343.0
6	14204	1	72	2	151.0	151.0
7	15195	1	1404	2	3861.0	3861.0
8	15471	1	256	2	454.0	454.0

RFM 통합 테이블 출력하기

- 최종 user_rfm 테이블을 출력하기

```

SELECT *
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.user_rfm`

```

[결과 이미지를 넣어주세요]

번호	CustomerID	purchase_cnt	item_cnt	rececy	user_total	user_average
1	12713	1	605	0	795.0	795.0
2	13298	1	96	1	360.0	360.0
3	13436	1	76	1	197.0	197.0
4	14569	1	79	1	227.0	227.0
5	15520	1	314	1	343.0	343.0
6	14204	1	72	2	151.0	151.0
7	15195	1	1404	2	3861.0	3861.0
8	15471	1	256	2	454.0	454.0

11-8. 추가 Feature 추출

1. 구매하는 제품의 다양성

- 1) 고객 별로 구매한 상품들의 고유한 수를 계산하기
- 2) user_rfm 테이블과 결과를 합치기
- 3) user_data 라는 이름의 테이블에 저장하기


```

CREATE OR REPLACE TABLE `project-23e56097-5f6c-4899-bd8.modulabs_project.user_data` AS
WITH unique_products AS (
  SELECT
    CustomerID,
    COUNT(DISTINCT StockCode) AS unique_products
  FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
  GROUP BY CustomerID
)

```

```
SELECT ur.*, up.* EXCEPT (CustomerID)
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.user_rfm` AS ur
JOIN unique_products AS up
ON ur.CustomerID = up.CustomerID;
```

[결과 이미지를 넣어주세요]




2. 평균 구매 주기

- 고객들의 쇼핑 패턴을 이해하는 것을 목표 (고객 별 재방문 주기 살펴보기)
 - 균 구매 소요 일수를 계산하고, 그 결과를 `user_data`에 통합

```
CREATE OR REPLACE TABLE `project-23e56097-5f6c-4899-bd8.modulabs_project.user_data` AS
WITH purchase_intervals AS (
  -- (2) 고객 별 구매와 구매 사이의 평균 소요 일수
  SELECT
    CustomerID,
    CASE WHEN ROUND(AVG(interval_), 2) IS NULL THEN 0 ELSE ROUND(AVG(interval_), 2) END AS average_in
    terval
  FROM (
    -- (1) 구매와 구매 사이에 소요된 일수
    SELECT
      CustomerID,
      DATE_DIFF(InvoiceDate, LAG(InvoiceDate) OVER (PARTITION BY CustomerID ORDER BY InvoiceDate), DA
      Y) AS interval_
    FROM
      `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
    WHERE CustomerID IS NOT NULL
  )
  GROUP BY CustomerID
)

SELECT u.*, pi.* EXCEPT (CustomerID)
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.user_data` AS u
LEFT JOIN purchase_intervals AS pi
ON u.CustomerID = pi.CustomerID;
```

[결과 이미지를 넣어주세요]



3. 구매 취소 경향성

- 고객의 취소 패턴 파악하기
 - 취소 빈도(cancel_frequency) : 고객 별로 취소한 거래의 총 횟수
 - 취소 비율(cancel_rate) : 각 고객이 한 모든 거래 중에서 취소를 한 거래의 비율
 - 취소 빈도와 취소 비율을 계산하고 그 결과를 `user_data`에 통합하기
(취소 비율은 소수점 두번째 자리)

```
CREATE OR REPLACE TABLE `project-23e56097-5f6c-4899-bd8.modulabs_project.user_data` AS

WITH TransactionInfo AS (
  SELECT
    CustomerID,
    COUNT(DISTINCT InvoiceNo) AS total_transactions,
    COUNT(DISTINCT CASE WHEN InvoiceNo LIKE 'C%' THEN InvoiceNo END) AS cancel_frequency
  FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.data`
  GROUP BY CustomerID
)

SELECT u.*, t.* EXCEPT(CustomerID), t.cancel_frequency / t.total_transactions AS cancel_rate
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.user_data` AS u
LEFT JOIN TransactionInfo AS t
ON u.CustomerID = t.customerID;
```

[결과 이미지를 넣어주세요]

쿼리 결과

작업 정보 결과 실행 세부정보 실행 그래프

이 문으로 이름이 user_data인 테이블이 교체되었습니다. 테이블로 이동

- 다양한 컬럼들을 활용하여 고객의 구매 패턴과 선호도를 보다 심층적으로 이해할 수 있도록 최종적으로 **user_data** 를 출력하기

```
SELECT *
FROM `project-23e56097-5f6c-4899-bd8.modulabs_project.user_data`
```

[결과 이미지를 넣어주세요]

쿼리 결과

작업 정보 결과 시각화 JSON 실행 세부정보 실행 그래프

명	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average	unique_products	average_interval	total_transactions	cancel_frequency	cancel_rate
1	13992	1	64	30	77.0	77.0	5	0.0	1	0	0.0
2	13723	1	43	217	200.0	200.0	6	0.0	1	0	0.0
3	15775	1	68	245	105.0	105.0	7	0.0	1	0	0.0
4	13786	1	136	367	230.0	230.0	7	0.0	1	0	0.0
5	13686	1	70	182	72.0	72.0	8	0.0	1	0	0.0
6	14699	1	77	214	109.0	109.0	8	0.0	1	0	0.0
7	16752	1	54	372	208.0	208.0	9	0.0	1	0	0.0
8	14212	1	1152	89	1070.0	1070.0	9	0.0	1	0	0.0
9	14055	1	216	106	726.0	726.0	10	0.0	1	0	0.0

회고

[회고 내용을 작성해주세요]

Keep :

함수	역할
REGEXP_REPLACE()	특정 문자 제거
REGEXP_EXTRACT()	패턴 추출
REGEXP_CONTAINS()	패턴 존재 확인

Problem :

- 자주 쓰는 문법은 외웠는데 아직 익숙하지 않은 문법들은 아직 힘들다..
- 추가 피쳐 만드는 부분은 어떤식으로 계산 해야하는지 떠오르긴 한데 쿼리문 작성으로 이어지지 않는다.
- VScode 환경보다 빅쿼리 환경이 아직 많이 불편하다

Try : 쿼리문 퀴즈를 매일 반복 연습이 필요하다

